1. Compreensão do Negócio

O objetivo é desenvolver um modelo capaz de identificar sinais de fadiga biomecânica em corredores a partir de dados de movimento coletados durante a corrida. O resultado esperado é classificar o estado do atleta, por exemplo, como “sem fadiga” ou “com fadiga”, permitindo identificar alterações no padrão de movimento que podem não ser perceptíveis pelo próprio corredor. O sucesso será medido pela capacidade do modelo de identificar corretamente esses estados e pela possibilidade de transformar o resultado em um indicador simples e interpretável de fadiga para apoiar treinadores e profissionais de fisioterapia.

2. Compreensão dos Dados

Serão utilizados dados de sensores inerciais (IMU) coletados durante atividades de corrida, podendo incluir aceleração, velocidade angular e orientação do corpo. Também poderão ser utilizados dados complementares, como velocidade, cadência, frequência cardíaca e percepção subjetiva de esforço (RPE).

Os atributos podem ser divididos em:

- **Numéricos contínuos:** aceleração, velocidade angular, frequência cardíaca e velocidade;
- **Numéricos discretos:** cadência, número de passadas etc.;
- **Categóricos:** estado de fadiga, como “fatigado” e “não fatigado”;
- **Temporais:** timestamp e sequência dos movimentos.

Os dados serão obtidos inicialmente de datasets públicos de corrida e fadiga, permitindo trabalhar com sinais reais de atletas.

3. Preparação dos Dados

Primeiramente será realizada uma análise exploratória para identificar valores ausentes, inconsistências, outliers e possíveis problemas de qualidade. Os sinais dos sensores deverão ser organizados temporalmente e segmentados em janelas de movimento para que cada trecho da corrida possa ser analisado pelo modelo.

Também serão avaliadas técnicas de normalização ou padronização das variáveis numéricas. Poderá ser necessário realizar tratamento de valores ausentes, remoção de registros inconsistentes e transformação das variáveis categóricas. A partir dos sinais brutos, serão extraídas características como média, desvio padrão, amplitude, variabilidade e características relacionadas à frequência dos movimentos.

Um cuidado importante será evitar **data leakage**, garantindo que dados do mesmo atleta não estejam simultaneamente nos conjuntos de treino e teste.

4. Modelagem

O problema será inicialmente tratado como uma **classificação binária**, buscando distinguir períodos de corrida com e sem sinais de fadiga.

Como primeiro modelo candidato será utilizado **XGBoost**, devido à sua capacidade de trabalhar bem com dados tabulares, relações não lineares e diferentes tipos de características. Além disso, sua utilização permitirá aplicar técnicas de explicabilidade, como SHAP, para identificar quais características biomecânicas mais influenciam a decisão do modelo.

Como baseline, poderá ser utilizado um modelo de **Regressão Logística** ou uma árvore de decisão simples. Posteriormente, poderão ser avaliados outros algoritmos, como Random Forest ou modelos específicos para séries temporais.

5. Avaliação

O desempenho será avaliado utilizando **F1-Score, Precision, Recall e ROC-AUC**, além da matriz de confusão. Como a identificação de fadiga é mais importante do que simplesmente maximizar a quantidade de acertos, será dada atenção especial ao **Recall da classe "fatigado"**, evitando que períodos de fadiga sejam classificados como normais.

O modelo será comparado inicialmente com uma **Regressão Logística**, utilizada como baseline. Também será realizada uma validação separando os atletas entre treino e teste, para verificar se o modelo consegue generalizar para corredores que não foram utilizados durante o treinamento.

6. Implantação

O resultado poderá ser utilizado como um protótipo de monitoramento de fadiga durante uma atividade de corrida. A partir dos dados de sensores, o sistema poderá processar janelas de movimento e apresentar um indicador de probabilidade de fadiga.

Após a implantação, deverão ser monitorados principalmente o desempenho do modelo, a taxa de falsos negativos, a distribuição das previsões e possíveis mudanças no padrão dos dados dos sensores. Também será importante acompanhar se o modelo mantém seu desempenho para diferentes atletas, velocidades e condições de treinamento.

O sistema será considerado inicialmente como uma **ferramenta de apoio à análise**, e não como um mecanismo de diagnóstico médico.

7. O que mudou da Versão 1 para a Versão 2?

Na primeira versão, o projeto estava definido de forma mais ampla como uma solução para identificar fadiga em corredores. Ao aplicar uma visão mais estruturada do CRISP-DM, percebemos que era necessário definir melhor o problema de negócio, a variável que será predita, os dados necessários e como o sucesso será mensurado.

Na segunda versão, transformamos a ideia em um problema de **classificação binária**, definimos possíveis fontes e tipos de dados, incluímos uma etapa de engenharia de características e estabelecemos métricas de avaliação. Também identificamos a necessidade de evitar data leakage entre atletas e incluímos a explicabilidade do modelo como parte importante do projeto. Dessa forma, o projeto passou de uma ideia geral para uma solução de Machine Learning mais mensurável, testável e aplicável.